

Lire le marché immobilier français par la donnée

DVF + INSEE · pipeline local · analyses territoriales

1 884 593 transactions uniques

Prototype analytique Homepedia — soutenance finale



Des données publiques riches, mais difficiles à comparer

Une transaction brute ne répond pas seule à une question territoriale.

- | | | |
|----|-----------------------|--|
| 01 | Explorer | prix, types de biens, périodes et territoires |
| 02 | Comparer | départements et régions avec un même périmètre |
| 03 | Contextualiser | population, revenu, chômage et pauvreté |

Pour qui ?

Analyste
Étudiant
Jury technique
Utilisateur métier

Objectif : comprendre, pas gérer des biens.

Deux familles INSEE, deux rythmes de données

DVF 2024

Transactions immobilières

Valeur foncière
Surface bâtie
Type de local
Commune + code postal

Grain : transaction

INSEE — fichiers

Socio-économie

Population 2024
Revenu médian 2021
Chômage T1 2025
Pauvreté 2021

Grain : département → région


INSEE — page HTML

Indices trimestriels

Collecte périodique
France / Île-de-France / province
Indices et variations annuelles

Polling ≠ fréquence de publication

Une chaîne complète, de la source à la décision



Le détail reste disponible dans SQLite ; Spark prépare les vues départementales pour accélérer l'exploration.

Les bibliothèques sont choisies selon le travail à réaliser

pandas

ingestion, nettoyage, jointures

**sqlite3 /
SQLAlchemy**

stockage et chargement SQL

Streamlit

interface et interaction

Altair / Matplotlib

graphiques et corrélations

PySpark

pré-agrégation distribuée DVF

PyMongo

documents, index uniques, upserts

**GeoPandas /
Folium**

jointures et cartes

**Requests /
BeautifulSoup**

collecte et parsing HTML

Traitement en mémoire, calcul distribué, stockage local et visualisation web.

Le code DVF transforme un fichier brut en faits rejouables



TARGET_COLS limite le schéma · **errors='coerce'** transforme les valeurs invalides · **replace** évite les doublons au jeu

Les indicateurs INSEE demandent des règles géographiques

Quatre traitements

Population → somme
Revenu → médiane
Chômage → moyenne
Pauvreté → moyenne

CSV / Excel → pandas → CSV, Parquet, SQLite

La clé géographique doit rester une chaîne

01	zéro initial conservé
2A / 2B	Corse traitée explicitement
971...	DOM sur trois chiffres
DEP → REG	jointure par référentiel

Chaque format répond à un mode d'accès différent

CSV

échange simple

lisible partout
scan complet coûteux

Parquet

analytique colonne

typé, compressé
lecture sélective

SQLite

service local

requêtes SQL, index
portable

GeoJSON

géographie

géométries pour
cartes choroplèthes

Parquet est surtout un format colonnaire, typé et compressé — pas simplement un découpage en fichiers.

La qualité transforme le volume en base analytique fiable

1 884 593

transactions DVF uniques dans la base finale

INDICATEUR CENTRAL

prix au m² = valeur foncière ÷ surface bâtie

01

Normaliser

dates, colonnes, codes postaux
sur 5 caractères

02

Dédoublonner

doublons exacts supprimés avant
chargement

03

Valider

surface > 0 · valeur ≥ 1 000 € ·
prix/m² valide

04

Rejouer

chargement replace : même
batch, même résultat

La preuve prioritaire est la base finale — pas le nombre de lignes supprimées.

Le contrat de données impose un langage commun

SQLite

MongoDB

Streamlit

Metabase


Tests

Noms physiques canoniques en français

transactions · population · revenus · chômage · pauvreté
analyse_departementale · analyse_regionale

Le document réduit la dérive ; migrations et tests restent nécessaires pour l'imposer.

Spark réduit 1,88 million de faits à 94 agrégats



`cast → filtre → prix/m2 → groupBy(dept) → toPandas()`

`toPandas()` est sûr ici parce que seule la petite sortie agrégée revient au driver.

Le driver orchestre, les workers exécutent



Transformations paresseuses → l'action déclenche réellement le calcul

La région réutilise le département au lieu de rescanner les faits



Prix régional = moyenne départementale pondérée par le nombre de transactions

Chaque stockage a un rôle explicite

SQLite

homepedia.db

faits DVF · indicateurs · agrégats

realtime_price.db

latest · history · runs

Lecture seule Streamlit · 6 retries · busy_timeout · WAL

MongoDB

Brut de collecte

Observations idempotentes

Dernier état

Miroirs documentaires ciblés

Complément documentaire — pas unique source de vérité

Contrat canonique commun

SQLite reste fiable grâce à une discipline de lecture et d'écriture

Lecture seule

Streamlit ouvre les bases avec
query_only

Retries

six tentatives avec délai croissant

busy_timeout

attend jusqu'à 30 secondes en cas
de verrou

WAL

sépare mieux lectures et écriture
du worker

Deux fichiers isolent les lectures analytiques des écritures périodiques.

MongoDB conserve trois niveaux documentaires complémentaires

raw_runs

une trace brute par run

debug du parsing

observations

une métrique par collecte

unicité métrique + date


latest

dernier état par métrique

upsert sur metric_uid

Les index uniques rendent les jeux idempotents, mais la double écriture n'est pas atomique.

Le “temps réel” est une collecte périodique contrôlée



État et audit

latest = état courant · history = changements · runs = chaque tentative

Simulation de démonstration

30 à 180 points · plusieurs scénarios
Jamais écrits dans les bases

Fréquence de collecte ≠ fréquence de publication · aucun Kafka

Chaque collecte est validée, persistée et auditée

01	UID	non vide
02	Période	format AAAA-T1...T4
03	Valeur	finie et dans une plage large
04	Source	URL présente

Un run garde toujours une preuve

points trouvés
points valides
history inséré / ignoré
erreurs DQ
statut ok, warn ou error

history ne change que si période ou valeur change ; runs enregistre chaque tentative.

Un filtre, un périmètre, toutes les vues



L'interface raconte le projet par six angles d'analyse

01

Standard

transactions, KPI, carte, distributions

02

Spark

agrégats départementaux pré-calculés

03

Socio-économie

population, revenu, chômage, pauvreté

04

Régions

carte, distributions, matrice à cinq variables

05

Méthodologie

choix techniques et chiffres de contrôle


06

Temps réel

latest, runs, history et simulation

Les pages sont différentes ; le périmètre filtré reste cohérent.

Docker Compose rend les services reproductibles sur une machine



Les conteneurs isolent les services ; ils ne transforment pas l'ordinateur en cluster multi-hôtes.

La corrélation décrit une relation, jamais une cause

Ce que mesure le coefficient

Direction de la relation
Intensité linéaire
Entre deux variables
Indépendamment des autres coefficients

Ce qu'il ne prouve pas

Aucune causalité
Aucune part d'un total
Aucune absence de facteur confondant
Aucune équivalence temporelle

Prix/m² · population · revenu · chômage · pauvreté : cinq variables, dix relations deux à deux.

Les résultats sont mesurables et réutilisables

1 884 593

transactions uniques

94

agréats départementaux

13

agréats régionaux · Corse incluse

Matrice régionale à cinq variables

Prix/m²

Population

Revenu

Chômage

Pauvreté

Chaque coefficient de corrélation est indépendant · aucun ne prouve une causalité

Les limites sont connues — et orientent la suite

Constat	Risque	Amélioration
SQLite local	concurrence d'écriture et absence de scale-out	PostgreSQL / moteur analytique selon la charge
Double écriture	aucune atomicité SQLite ↔ MongoDB	outbox ou réconciliation explicite
Source HTML	scraper sensible aux changements de structure	fixtures, alertes de fraîcheur, fallback
Cluster mono-machine	distribution pédagogique, résilience limitée	stockage distribué et plusieurs hôtes si besoin

Prototype démontrable aujourd'hui · trajectoire de production explicite

Homepedia rend une chaîne data complexe lisible et défendable

Fiable

nettoyage, idempotence, contrat commun

Mesurable

1,88 M de faits · 94 départements · 13 régions

Lucide

polling, mono-machine, cohérence éventuelle

Prochaine étape : tests de contrat · observabilité · stockage scalable