

Lire le marché immobilier français par la donnée

DVF + INSEE · pipeline local · analyses territoriales

1 884 593 transactions uniques

Prototype analytique Homepedia — soutenance finale



Des données publiques riches, mais difficiles à comparer

Une transaction brute ne répond pas seule à une question territoriale.

- | | | |
|----|-----------------------|--|
| 01 | Explorer | prix, types de biens, périodes et territoires |
| 02 | Comparer | départements et régions avec un même périmètre |
| 03 | Contextualiser | population, revenu, chômage et pauvreté |

Pour qui ?

Analyste
Étudiant
Jury technique
Utilisateur métier

Objectif : comprendre, pas gérer des biens.

Deux familles INSEE, deux rythmes de données

DVF 2024

Transactions immobilières

Valeur foncière
Surface bâtie
Type de local
Commune + code postal

Grain : transaction

INSEE — fichiers

Socio-économie

Population 2024
Revenu médian 2021
Chômage T1 2025
Pauvreté 2021

Grain : département → région


INSEE — page HTML

Indices trimestriels

Collecte périodique
France / Île-de-France / province
Indices et variations annuelles

Polling ≠ fréquence de publication

Une chaîne complète, de la source à la décision



Le détail reste disponible dans SQLite ; Spark prépare les vues départementales pour accélérer l'exploration.

La qualité transforme le volume en base analytique fiable

1 884 593

transactions DVF uniques dans la base finale

INDICATEUR CENTRAL

prix au m² = valeur foncière ÷ surface bâtie

01

Normaliser

dates, colonnes, codes postaux
sur 5 caractères

02

Dédoublonner

doublons exacts supprimés avant
chargement

03

Valider

surface > 0 · valeur ≥ 1 000 € ·
prix/m² valide


04

Rejouer

chargement replace : même
batch, même résultat

La preuve prioritaire est la base finale — pas le nombre de lignes supprimées.

Spark réduit 1,88 million de faits à 94 agrégats



`cast → filtre → prix/m2 → groupBy(dept) → toPandas()`

`toPandas()` est sûr ici parce que seule la petite sortie agrégée revient au driver.

Chaque stockage a un rôle explicite

SQLite

homepedia.db

faits DVF · indicateurs · agrégats

realtime_price.db

latest · history · runs

Lecture seule Streamlit · 6 retries · busy_timeout · WAL


MongoDB

Brut de collecte
Observations idempotentes
Dernier état
Miroirs documentaires ciblés

Complément documentaire — pas unique source de vérité

Contrat canonique commun

Le “temps réel” est une collecte périodique contrôlée



État et audit

latest = état courant · history = changements · runs = chaque tentative

Simulation de démonstration

30 à 180 points · plusieurs scénarios
Jamais écrits dans les bases

Fréquence de collecte ≠ fréquence de publication · aucun Kafka

Un filtre, un périmètre, toutes les vues



Les résultats sont mesurables et réutilisables

1 884 593

transactions uniques

94

agrégats départementaux

13

agrégats régionaux · Corse incluse

Matrice régionale à cinq variables

Prix/m²

Population

Revenu

Chômage

Pauvreté

Chaque coefficient de corrélation est indépendant · aucun ne prouve une causalité

Les limites sont connues — et orientent la suite

Constat	Risque	Amélioration
SQLite local	concurrence d'écriture et absence de scale-out	PostgreSQL / moteur analytique selon la charge
Double écriture	aucune atomicité SQLite ↔ MongoDB	outbox ou réconciliation explicite
Source HTML	scraper sensible aux changements de structure	fixtures, alertes de fraîcheur, fallback
Cluster mono-machine	distribution pédagogique, résilience limitée	stockage distribué et plusieurs hôtes si besoin

Prototype démontrable aujourd'hui · trajectoire de production explicite

Homepedia rend une chaîne data complexe lisible et défendable

Fiable

nettoyage, idempotence, contrat commun

Mesurable

1,88 M de faits · 94 départements · 13 régions

Lucide

polling, mono-machine, cohérence éventuelle

Prochaine étape : tests de contrat · observabilité · stockage scalable